

Métodos de muestreo: Monte Carlo Markov Chain

David Montaña Castro

Metropolis-Hastings

1.- Sea $Y \sim \text{Binomial}(n, p)$ con n fijo. Considere el logaritmo de los momios $\theta = \log(\frac{p}{1-p})$ tal que su distribución inicial (prior) es $\theta \sim \text{Normal}(\mu, \sigma^2)$, con $\mu = 1$ y $\sigma^2 = 0.16$. Suponga que se observan $n = 10$ y $y = 7$.

Use el algoritmo de Metropolis-Hastings para simular la distribución final (posterior) de p , y de la θ .

Respuesta

Por conveniencia iniciaré por poner la verosimilitud en términos de θ , ya que de esta se conocen sus hiperparámetros por ser la distribución a priori.

No sin antes despejar de la igualdad dada la p .

$$\begin{aligned}\theta &= \ln\left(\frac{p}{1-p}\right) \\ e^\theta &= \frac{p}{1-p} \\ e^\theta(1-p) &= p \\ e^\theta - pe^\theta &= p \\ e^\theta &= p + pe^\theta \\ e^\theta &= p(1 + e^\theta) \\ p &= \frac{e^\theta}{1 + e^\theta}\end{aligned}$$

Verosimilitud

Dado que $Y \sim \text{Binomial}(n, p)$:

$$\begin{aligned}f(y|p) &= \binom{n}{y} p^y (1-p)^{n-y} \\ &= \binom{n}{y} \left(\frac{p}{1-p}\right)^y (1-p)^n \\ &= \binom{n}{y} e^{y \ln(\frac{p}{1-p})} (1-p)^n \\ &= \binom{n}{y} e^{y\theta} \left(1 - \frac{e^\theta}{1 + e^\theta}\right)^n \\ &= \binom{n}{y} e^{y\theta} \left(\frac{1 + e^\theta}{1 + e^\theta} - \frac{e^\theta}{1 + e^\theta}\right)^n \\ &= \binom{n}{y} e^{y\theta} \left(\frac{1}{1 + e^\theta}\right)^n\end{aligned}$$

Prior

Por hipótesis, se sabe que $\theta \sim Normal(\mu = 1, \sigma^2 = 0.16)$

Posterior θ

También por hipótesis, se sabe que $y = 7$ y $n = 10$

$$\begin{aligned} f(\theta|y = 7, n = 10) &= f(\theta)f(y|\theta) \\ &= Normal(\mu = 1, \sigma^2 = 0.16) \binom{10}{7} e^{7\theta} \left(\frac{1}{1 + e^\theta}\right)^{10} \\ &\propto e^{-\frac{(\frac{\theta-1}{\sqrt{0.16}})^2}{2}} e^{7\theta} \left(\frac{1}{1 + e^\theta}\right)^{10} \end{aligned}$$

La distribución de la posterior luce complicada de calcular, incluso de ponerla de alguna forma conocida. Es por eso que se necesita utilizar una técnica de muestreo estocástico.

Metropolis-Hastings

```
N = 50000

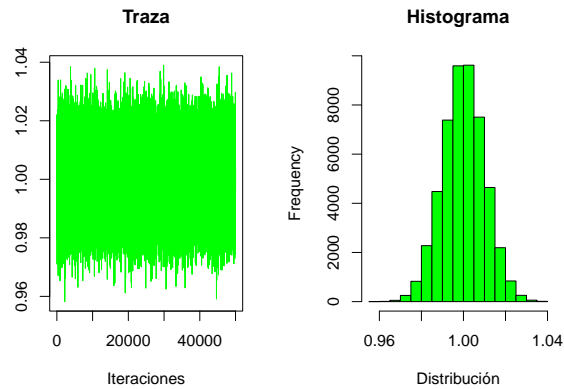
mu = 1
sigma = sqrt(.16)

X = array(0, dim=c(1,N))

X[1,] = rep(rnorm(n = 1, mean = mu, sd = 0.001 ), N)

for (j in 2:N) {
  y = rnorm(n = 1, mean = mu, sd = 0.01)
  alpha = min(dnorm(X[1, j-1],mu,sigma)*exp(7*y)*(1/(1+exp(y)))^10/(dnorm(y,mu,sigma)*exp(7*X[j-1]))*(1/
  X[1,j] = X[1, j-1] + (y[1] - X[1,j-1]) * (runif(1)<alpha)
}

par(mfrow = c(1,2))
plot(X[1,], type = "l", main = "Traza", xlab = "Iteraciones", ylab = "", col = "green")
hist(X[1,], main = "Histograma", col = "green", xlab = "Distribución" )
```




Posterior P

Dada la simulación de los datos, se pueden obtener la distribución posterior de P aplicando la transformación inicial.

```
X_ = as.vector(X)

Y = exp(X_)/(1 + exp(X_)) #log(X_/(1-X_))

par(mfrow = c(1,2))
plot(Y, type = "l", main = "Traza", xlab = "Iteraciones", ylab = "", col = "blue")
hist(Y, main = "Histograma", col = "blue", xlab = "Distribución" )
```



Simulación con JAGS

Se puede simular con ayuda de JAGS la distribución. No supe como indicarle que tomara un valor en particular ($y = 7$) pero sí se puede generar una muestra de la distribución.

Posterior θ

```

data <- list(
  n = 10,
  theta0 = 1,
  tau2inv = 1/.16
)

param <- c("theta")

fit <- jags.model("E1_T4.bug", data,n.chains=3)

```

```

Compiling model graph
  Resolving undeclared variables
  Allocating nodes
Graph information:
  Observed stochastic nodes: 0
  Unobserved stochastic nodes: 2
  Total graph size: 9

```

```

Initializing model

```



```

update(fit,1000)

sample <- coda.samples(fit, param, n.iter=5000, thin=1)

plot(sample,main = "Posterior Theta")

```



```
summary(sample)
```

```
Iterations = 1001:6000
```

```
Thinning interval = 1
```

```
Number of chains = 3
```

```
Sample size per chain = 5000
```

1. Empirical mean and standard deviation for each variable,
plus standard error of the mean:

Mean	SD	Naive SE	Time-series SE
0.996597	0.399223	0.003260	0.003227

2. Quantiles for each variable:

2.5%	25%	50%	75%	97.5%
0.2164	0.7291	0.9950	1.2659	1.7824


Posterior P

De igual manera, con las muestras ya obtenidas de la simulación anterior puedo aplicar la transformación para obtener la distribución posterior de P.


```
Y = exp(sample[[1]])/(1 + exp(sample[[1]]))
```

```
plot(Y, main = "Posterior P")
```

Posterior P



Posterior P



N = 5000 Bandwidth = 0.01483

Muestreo de Gibbs

2. Sea X_1, \dots, X_n una muestra aleatoria de una distribución Normal truncada, definida en $X > 0$, $X \sim \text{NormalTrunc}(\mu, \sigma)I(0, \infty)$. Considere las distribuciones prior $\mu \sim \text{Normal}(\mu_0, \tau_0^2)$ y $\sigma^2 \sim \text{InvGamma}(a, b)$.

Use el algoritmo de muestreo de Gibbs para estimar la distribución posterior de μ y σ^2 . Simule un conjunto de datos para ejemplificar.

Adicionalmente, incluye la estimación usando JAGS.

Respuesta